

Báo Cáo Phân Tích Tổng Quan Về Phương Pháp GOD (CVPR 2026) Và Hướng Cải Tiến

Nghiên cứu & Tổng hợp chuyên sâu

Ngày 23 tháng 9 năm 2026

Bản tổng hợp chuyên sâu và đầy đủ về phương pháp **GOD (Geometry-driven OOD Detectors)** từ bài báo gốc (CVPR 2026) và **Đề xuất Cải tiến (Dynamic Layer Splitting)** từ tài liệu phân tích khoảng trống nghiên cứu.

1 Bối cảnh & Động lực Nghiên cứu

- **Bài toán Class-Incremental Learning (CIL):** Hệ thống AI cần học liên tục các lớp đối tượng mới theo thời gian mà không được phép lưu trữ dữ liệu cũ (*Exemplar-Free CIL*). Thách thức lớn nhất là *Quên lãng thảm khốc (Catastrophic Forgetting)*.
- **Thất bại của các Mô hình Tiền huấn luyện (PTMs) hiện tại:** Dù tận dụng PTMs (như ViT-B/16), các phương pháp cũ thường dùng bộ phân loại mở rộng chung (*Single Expanding Classifier*) gây lệch dự đoán về lớp mới (*Task-Recency Bias*) hoặc dùng nhiều bộ phân loại riêng lẻ (*Multi-Fixed Classifiers*) phụ thuộc vào bộ dự đoán Task-ID phụ trợ vốn rất dễ bị quên bài.
- **Luận điểm cốt lõi của GOD:** Nếu mỗi đầu tác vụ (*Task Head*) vừa có khả năng nhận diện lớp trong phân phối (*In-Distribution - IND*), vừa có khả năng từ chối mẫu ngoài phân phối (*Out-of-Distribution - OOD*), bài toán CIL sẽ diễn ra tự nhiên: mẫu thử sẽ chỉ được chấp nhận bởi đầu tác vụ coi nó là IND và bị từ chối ở tất cả các đầu còn lại.

2 Lý thuyết Kiến trúc & Cơ chế Hoạt động của GOD

2.1 Cơ sở Lý thuyết Hình học (Geometric Foundation)

GOD thiết lập 2 giả định hình học để tối ưu khoảng cách Mahalanobis và biên phân tách OOD:

1. **Phân tách Liên lớp (Inter-class Separation):** Tối đa hóa góc phân tách giữa các vector gốc của các lớp.
2. **Co cụm Nội lớp (Intra-class Compactness):** Tối thiểu hóa phương sai đặc trưng nội lớp để gom cụm dữ liệu chặt quanh gốc.

2.2 Mốc ETF Anchors & Hàm Mất mát Kép (Loss Functions)

Equiangular Tight Frame (ETF) Anchors: Thay vì học trọng số bộ phân loại, GOD cố định các mốc $E_t = \{e_{t,1}, \dots, e_{t,C_t}\}$ phân bố chặt đều góc trên mặt cầu đơn vị $\mathbb{S}^{d-1}$:

$$\langle e_{t,i}, e_{t,j} \rangle = \begin{cases} 1, & i = j, \\ -\frac{1}{C_t - 1}, & i \neq j. \end{cases} \quad (1)$$

Hàm biến đổi đặc trưng 2 giai đoạn:

$$z_t(x) = \frac{\text{TP}_t(\text{RP}(f_t(x)))}{\|\text{TP}_t(\text{RP}(f_t(x)))\|}, \quad (2)$$

trong đó, *Random Projection* (RP) (cố định) giúp nâng chiều đặc trưng để tăng tính phân tách tuyến tính, và *Task-specific Projection* (TP_t) căn chỉnh đặc trưng vào mốc ETF.

Mất mát kết hợp ($\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{etf}} + \mathcal{L}_{\text{arc}}$):

- $\mathcal{L}_{\text{etf}}$ (*Temperature-scaled Cross-Entropy*): Khai thác biên góc toàn cục ETF để đảm bảo phân tách liên lớp.
- $\mathcal{L}_{\text{arc}}$ (*ArcFace Loss với Additive Angular Margin m*): Mở rộng biên góc nội lớp, bắt các mẫu có cụm chặt xung quanh mốc ETF tương ứng.

2.3 Kiến trúc LoRA Lai Tiết kiệm Tham số (Parameter-efficient Hybrid LoRA)

Dựa trên quan sát thực nghiệm rằng đặc trưng ở các tầng nông có độ tương đồng Cosine rất cao giữa các tác vụ (chứa tri thức thị giác chung), trong khi đặc trưng ở các tầng sâu có độ phân hóa lớn:

- **Shared LoRA (SL)** ($l \leq 9$, ViT-B/16): Được huấn luyện 1 lần duy nhất ở Tác vụ 1, sau đó đóng băng vĩnh viễn để làm khung tri thức nền.
- **Task-specific LoRA** (TL_t) ($l > 9$): Mỗi tác vụ mới $t > 1$ chỉ khởi tạo một bộ TL_t nhẹ ở 3 tầng sâu (kế thừa từ TL_{t-1}). Giúp số tham số huấn luyện mỗi tác vụ chỉ tốn 2.64M.

2.4 Chiến lược Suy luận 2 Chế độ (Inference Strategy)

Tích lũy bộ thích ứng toàn cục TL_{ema} qua trung bình động lũy thừa:

- **Coarse Mode (Suy luận Nhanh):** Chạy ảnh qua SL + TL_{ema} đúng 1 lượt truyền xuôi (*forward pass*) qua tất cả đầu TP_t để lấy dự đoán sơ bộ.
- **Refined Mode (Suy luận Tinh chỉnh):** Dùng dự đoán sơ bộ chọn ra Top- k ($k = 3$) lớp có độ tin cậy cao nhất, tái mã hóa đặc trưng chỉ qua đúng các bộ TL_t tương ứng (*Top-k Sparse Activation*) để đạt độ chính xác tối đa.

3 Khoảng trống Nghiên cứu (Research Gap) & Đề xuất Cải tiến

3.1 Hạn chế của GOD Gốc (Static Layer Splitting)

- **Cố định ngưỡng $k = 9$ thô cứng:** Việc mặc định đóng băng 9 tầng nông dựa trên quan sát ảnh tự nhiên (ImageNet-R, Stanford Cars).
- **Thất bại khi Domain Shift lớn:** Khi học các miền dữ liệu đặc thù (ảnh y tế X-quang, ảnh vệ tinh radar SAR, ảnh siêu phổ), các tầng nông bị đóng băng không thể trích xuất kết cấu đặc thù của miền mới (*Filter Mismatch*), làm suy giảm nghiêm trọng chất lượng biểu diễn đặc trưng.

3.2 Đề xuất Cải tiến: Phân chia Tầng LoRA Động (Dynamic & Adaptive Layer Splitting)

Tự động hóa quá trình phân chia tầng bằng cơ chế 2 cấp độ:

1. **Chẩn đoán Macro (Gradient Variance / Fisher Information):** Trong giai đoạn warm-up ban đầu của tác vụ mới, hệ thống đo biến thiên độ dốc ở các tầng. Nếu *Gradient Variance* ở các tầng nông tăng đột biến (dấu hiệu dữ liệu lạ), hệ thống sẽ hạ ngưỡng k xuống (giải phóng thêm các tầng nông để học bộ thích ứng mới).
2. **Điều phối Micro (Mô-đun Gating tự động):** Tích hợp một bộ định tuyến router tại từng tầng Transformer để pha trộn mềm tỷ lệ đóng góp giữa Shared LoRA và Task-specific LoRA:

$$\text{Output}_l = \alpha_l \cdot \text{Shared_LoRA}_l(x) + \beta_l \cdot \text{Task_Specific_LoRA}_{l,t}(x) \quad (\text{với } \alpha_l + \beta_l = 1). \quad (3)$$

Hiệu quả: Tác vụ gần ảnh tự nhiên $\rightarrow$ Giữ k cao (tiết kiệm bộ nhớ); Tác vụ miền dữ liệu lạ $\rightarrow$ Tự động hạ k và điều chỉnh (α_l, β_l) để thích ứng tốt mà không gây quên lãng tri thức cũ.